

Klasyfikacja i rekonstrukcja obrazów z sygnału EEG

Raport z projektu

Paulina Kędzierska
Szymon Konarski

22.08.2026

1. Cel projektu

Celem projektu było sprawdzenie, czy modele sztucznej inteligencji są w stanie sklasyfikować i odtworzyć obrazy wyłącznie na podstawie danych EEG. W tym celu zapoznano się z procedurą badania z zakresu neurobiologii oraz przeanalizowano dostępne dane. Następnie odpowiednio przygotowano je do wykorzystania przez wybrany model sieci neuronowej i przeprowadzono próby klasyfikacji oraz rekonstrukcji obrazów. Cały przebieg projektu, poczynione obserwacje oraz wyciągnięte wnioski zostały przedstawione w niniejszym raporcie.

2. Założenia

2.1. Struktura danych

W badaniu wykorzystano obrazy należące do 11 kategorii: abstrakt, samolot, jabłko, banan, ptak, łódź, samochód, pies, osoba, pociąg oraz zebra. Kategoria abstrakt różniła się od pozostałych, ponieważ zamiast zdjęć zawierała prostą grafikę złożoną z figur geometrycznych.

W każdej kategorii znajdowało się 20 obrazów, co dawało łącznie 220 unikalnych obrazów. Zestaw ten był prezentowany w sześciu seriach, więc każdy obraz pojawiał się podczas badania sześć razy. W efekcie dla jednego badanego otrzymano łącznie 1320 prób, czyli po 220 prób w każdej serii.

Każda próba miała przypisany numer serii oraz numer próby. W pliku z zapisanymi zdarzeniami znajdowały się również informacje o czasie wystąpienia danego zdarzenia oraz jego rodzaju. Dzięki temu można było później określić, kiedy dokładnie pojawił się konkretny obraz i jaki fragment sygnału EEG odpowiadał jego prezentacji.

Takie uporządkowanie danych było szczególnie istotne z punktu widzenia dalszej analizy. Pozwalało ono połączyć sygnał EEG z konkretnym obrazem i jego kategorią, a także rozdzielić poszczególne etapy pojedynczej próby.

2.2. Przebieg badania

Przed rozpoczęciem właściwego badania uczestnik uzupełniał krótką ankietę oraz otrzymał instrukcję dotyczącą przebiegu eksperymentu. Następnie wykonano krótki etap przygotowawczy, w którym rejestrowano aktywność EEG przy zamkniętych oczach, a później przy otwartych oczach. Po tym etapie rozpoczęła się właściwa część badania.

Badanym był student realizujący projekt, który przed rozpoczęciem eksperymentu nie miał dostępu do obrazów wykorzystywanych podczas badania. Uczestnik miał założony czepek EEG z elektrodami, a jego zadaniem było skupienie wzroku na wyświetlanych obrazach i późniejsze ich opisanie.

Każda próba przebiegała według tego samego schematu:

*fiksacja → czarny ekran → obraz → czarny ekran → opis obrazu →
naciśnięcie spacji → czarny ekran*

Na początku pojawiał się punkt fiksacji, na którym badany miał skupić wzrok. Następnie na krótko wyświetlany był czarny ekran, po którym pojawiał się właściwy obraz. Obraz był prezentowany przez około 0,5 sekundy.

Po obejrzeniu każdego obrazu uczestnik miał w jednym zdaniu opisać to, co zobaczył. Kiedy kończył opis, naciskał klawisz spacji. W tym momencie zapisywane było zdarzenie `SPACE_PRESSED`, a następnie pojawiał się krótki czarny ekran i rozpoczynała się kolejna próba.

Poszczególne etapy były zapisywane w pliku z wykorzystaniem specjalnych znaczników. Przykładowo, `FIXATION` oznaczało rozpoczęcie fiksacji, `IMAGE_ON` moment pojawienia się obrazu, `DESCRIBE_SCREEN` rozpoczęcie etapu opisu, a `SPACE_PRESSED` zakończenie opisu przez badanego. Dzięki temu późniejsza analiza nie wymagała zgadywania, w którym momencie prezentowany był dany obraz.

Całe badanie zostało podzielone na sześć serii po 220 prób. Pomiedzy seriami uczestnik miał przerwy, dzięki czemu mógł odpocząć przed rozpoczęciem kolejnej części badania. Łączny czas rejestracji wyniósł około 2,5 godziny, wliczając przygotowanie, przerwy oraz poszczególne etapy badania.

Czas potrzebny na wykonanie pojedynczej próby nie był zawsze taki sam.

Sama prezentacja obrazu trwała około 0,5 sekundy, natomiast etap opisywania zależał od badanego i od tego, ile czasu potrzebował on na przygotowanie odpowiedzi. Z tego powodu poszczególne serie trwały różną ilość czasu.

Po zakończeniu głównej części eksperymentu przeprowadzono również etap końcowy, obejmujący ankietę po badaniu. Pozwoliło to zebrać dodatkowe informacje dotyczące udziału w eksperymencie, niezwiązane bezpośrednio z samym zapisem EEG.

W rezultacie otrzymano zbiór danych zawierający zarówno sygnał EEG, jak i informacje o dokładnym przebiegu eksperymentu. Dzięki zapisanym znacznikom zdarzeń możliwe jest określenie, kiedy uczestnik oglądał konkretny obraz, kiedy go opisywał oraz kiedy zakończył daną próbę. Stanowi to podstawę do dalszego przetwarzania i analizy zebranych danych.

3. Użyte środowisko programistyczne, biblioteki i narzędzia

3.1. Środowisko programistyczne

PyCharm, Terminal linuxowy (po zainstalowaniu pyhona3, potrzebnych pakietów i bibliotek na systemie operacyjnym Ubuntu), Google Colab (powiedzmy, że to środowisko programistyczne :p).

3.2. Biblioteki

m.in. MNE, matplotlib, pandas, numpy, sklearn.

3.3. Narzędzia


Tu może być tak naprawdę cokolwiek: gen AI, które nam pomagało (Gemini, Claude, ChatGPT), jakieś napisane przez nas skrypty albo inne fajne rzeczy, które nie są jedną z tych trzech innych kategorii w tym podrozdziale.

3.4. Sieci neuronowe

Użyte przez nas finalnie sieci neuronowe. Można tu też wspomnieć o tych, które rozważaliśmy, ale ostatecznie z jakiegoś powodu odrzuciliśmy.

4. Przygotowanie danych

Przygotowanie danych zrealizowano w postaci potoku przetwarzania (ang. *pipeline*), złożonego z szeregu funkcji wykonywanych w ustalonej kolejności. Każda z nich odpowiadała za pojedynczy etap obróbki sygnału – od wczytania surowego zapisu, przez porządkowanie i czyszczenie danych, aż po podział na próby i zapis w postaci gotowej do wykorzystania przez model.



Rys. 1. Ogólny schemat potoku przygotowującego dane do nauki sieci neuronowej.

Poniżej opisano finalną postać potoku oraz wskazano w jaki sposób zmieniał się on w trakcie realizacji projektu.

4.1. Wczytanie surowych danych

Pierwszym etapem było wczytanie surowego zapisu EEG. Dane każdego badanego przechowywane były w pliku w formacie EDF (ang. *European Data Format*), będącym standardem stosowanym do zapisu sygnałów biomedycznych.

```

#-----Wczytywanie danych-----
def load_data(nick):
    global raw_data

    raw_data = mne.io.read_raw_edf(f"assets/{nick}.raw.edf", preload=True, infer_types=True) # załaduj do pamięci, typ EEG do znanych kanałów
    print("\n#####\n")
    print(raw_data) #Informacje o kanałach i obiekcie
    print("\n#####\n")
    print(raw_data.info) #Informacje o kanałach i obiekcie
    print("\n#####\n")
    print(raw_data.describe()) #Informacje o kanałach i obiekcie
    print("\n#####\n")

```

Rys. 2. Fragment kodu pipeline’u przygotowującego dane, odpowiedzialny za wczytanie surowych danych do programu.

Do ich odczytu wykorzystano funkcję `read_raw_edf()` z biblioteki MNE. Sygnał wczytano od razu w całości do pamięci operacyjnej (parametr `preload=True`), co było konieczne, aby możliwe było jego późniejsze filtrowanie i modyfikacja. Włączono również automatyczne rozpoznawanie typów kanałów na podstawie ich nazw (parametr `infer_types=True`). Po wczytaniu wyświetlono podstawowe informacje o nagraniu – m.in. liczbę i nazwy kanałów oraz częstotliwość próbkowania – w celu wstępnej weryfikacji poprawności odczytanych danych.

4.2. Mapowanie kanałów

Kolejnym krokiem przygotowania danych było uporządkowanie informacji o kanałach. W tym celu jednolicono ich nazwy, przypisano im odpowiednie typy oraz określono położenie elektrod zgodnie z międzynarodowym standardem 10–20.

Standard 10–20 (ang. *international 10–20 system*) to jeden ze sposobów rozmieszczania i nazywania elektrod na powierzchni głowy. Jego nazwa wynika ze sposobu wyznaczania pozycji elektrod: rozmieszcza się je w odstępach stanowiących około 10% lub 20% odległości pomiędzy charakterystycznymi punktami anatomicznymi głowy – nasion (zagłębienie u nasady nosa), inion (guzowatość potyliczna) oraz punktami przedusznymi po obu stronach głowy. Dzięki temu możliwe jest stosowanie podobnego układu elektrod niezależnie od kształtu i rozmiaru głowy badanego, co ułatwia porównywanie wyników uzyskanych dla różnych osób.

Nazwa każdej elektrody koduje jej położenie. Litera (lub zestaw liter) wskazuje jej położenie na powierzchni głowy:

- Fp – okolice czołowo-biegunową,
- F – czołową,
- C – centralną,
- T – skroniową,
- P – ciemieniową,
- O – potyliczną.

W standardzie mogą występować również oznaczenia pośrednie, takie jak FC, CP czy PO, jednak nie odnotowano ich dla opisywanego badania.

Liczby nieparzyste oznaczają lewą stronę głowy, a parzyste prawą. Im większa liczba, tym dalej od linii środkowej znajduje się elektroda. Litera *z* (od ang. *zero*) oznacza położenie na linii środkowej. Przykładowo, Fp1 oznacza elektrodę znajdującą się po lewej stronie w okolicy czołowo-biegunowej, Fp2 – jej odpowiednik po prawej stronie, natomiast elektroda Cz leży centralnie na linii środkowej. W niniejszym badaniu szczególnie istotne były elektrody O1 i O2, znajdujące się odpowiednio po lewej i prawej stronie w okolicy potylicznej, ponieważ rejestrowana aktywność była związana m.in. z odpowiedzią kory wzrokowej.

Przygotowanie kanałów przebiegało w kilku krokach, których kod przedstawiono na rys. 3.

```

#-----Zmiana nazw kanałów-----
def change_channel_names():
    global raw_data

    new_names = { ch:ch.split('-')[0].strip() for ch in raw_data.ch_names}
    raw_data.rename_channels(new_names)

#-----Zmiana typów kanałów-----
def change_channel_types():
    global raw_data

    ch_types = {}
    for ch in raw_data.ch_names:
        if ch in ['X1:', 'X2:', 'X3:', 'CM']:
            ch_types[ch] = 'misc'
        elif ch in ['Trigger', 'Event']:
            ch_types[ch] = 'stim'
        elif ch[:3] == "Imp":
            raw_data.drop_channels([ch])
        else:
            ch_types[ch] = 'eeg'
    raw_data.set_channel_types(ch_types)

#-----Zmiana montażu i referencji-----
def change_montage_and_reference():
    global raw_data

    montage = mne.channels.make_standard_montage('standard_1020')
    raw_data.set_montage(montage, on_missing='ignore')

    raw_data.set_eeg_reference(ref_channels=['A1', 'A2'])

```

Rys. 3. Fragment kodu pipeline'u przygotowującego dane, odpowiedzialny za mapowanie kanałów na standard `standard_1020`.

Na początku ujednolicono nazwy kanałów poprzez usunięcie fragmentów znajdujących się po znaku `-`. W tym celu wykorzystano funkcję `split()`, która pozwoliła pozostawić pierwszą część każdej nazwy. Przykładowo, `Fp1-REF` zostało zmienione na `Fp1`. W przypadku kanałów zawierających dwukropek, np. `X1:` lub `Ax:`, znak ten pozostawał częścią nazwy.


Następnie każdemu kanałowi przypisano odpowiedni typ. Elektrody EEG oznaczono jako `eeg`, kanały pomocnicze – wejścia analogowe `X1-X3` oraz elektrodę trybu wspólnego `CM` – jako `misc`, a kanały ze znacznikami zdarzeń (`Trigger`, `Event`) jako `stim`. Kanały zawierające pomiary impedancji (o nazwach rozpoczynających się od `Imp`) usunięto, ponieważ nie niosą informacji przydatnej w dalszej analizie.

Podział kanałów na poszczególne typy był istotny podczas dalszego przetwarzania danych, ponieważ kolejne operacje, takie jak montaż, filtrowanie czy analiza

ICA, domyślnie obejmują wyłącznie kanały typu `eeg`. Kanały `misc` przechowują dodatkowe informacje, które nie są traktowane jak sygnał mózgowy, natomiast kanały `stim` pozwalają określić moment wystąpienia poszczególnych zdarzeń. Z tego powodu kanały `misc` i `stim` nie zostały wycięte ze zbioru danych, tylko jedynie odpowiednio oznaczone.

Po uporządkowaniu kanałów przypisano do danych montaż `standard_1020`. Wykorzystano w tym celu funkcję `make_standard_montage()`, a następnie `set_montage()`. Montaż zawiera informacje o przestrzennym położeniu elektrod, dzięki czemu nazwy kanałów, mogły zostać powiązane z ich pozycjami na głowie. Parametr `on_missing='ignore'` pozwolił na pominięcie kanałów, dla których nie znaleziono odpowiedniej pozycji w standardzie 10-20, bez zgłaszania błędu.

Poprawność przypisania montażu sprawdzono za pomocą funkcji `plot_sensors(kind='topomap', show_names=True)`. Fragment ten nie znalazł się w funkcji, ponieważ służył typowo do sprawdzenia, czy mapowanie kanałów przebiegło pomyślnie. Wynik przedstawiono na rys. 4.



Rys. 4. Rozmieszczenie elektrod EEG po przypisaniu montażu **standard_1020**.

Na wykresie elektrody EEG zostały rozmieszczone zgodnie ze standardem 10–20. Widoczna jest symetria układu względem linii środkowej głowy oraz podział elektrod na lewą i prawą stronę. Kanały pomocnicze nie są przedstawione jako elektrody na mapie, ponieważ nie mają przypisanych pozycji w zastosowanym montażu. Uzyskany wynik potwierdził poprawność przypisania nazw elektrod do standardowych pozycji przestrzennych. Przygotowane w ten sposób dane mogły zostać wykorzystane w kolejnych etapach analizy.

Ostatnim krokiem tej części przygotowania danych było ustalenie sposobu referencji sygnału. Wartości rejestrowane na poszczególnych elektrodach mają charakter względny, dlatego wymagają odniesienia do wspólnego punktu. Jako referencję przyjęto uśrednienie sygnału z elektrod usznych A1

i A2, co jest jednym z typowych rozwiązań stosowanych w badaniach EEG. Operację tę wykonano funkcją `set_eeg_reference(ref_channels=['A1', 'A2'])`.

4.3. Ciąg dalszy :pp

5. Klasyfikacja obrazów

Jak ją zrobiliśmy i co wyszło.

6. Rekonstrukcja obrazów

Jak ją zrobiliśmy i co wyszło.

7. Podsumowanie projektu - uwagi i wnioski

Jaka wyszła nam zgodność, co może być tego przyczyną i ewentualnie inne cenne uwagi.